







PYTHON PARA PLN

Introdução ao Python

Roney Lira de Sales Santos roneysantos@usp.br Rogério Figueredo de Sousa rogerfig@usp.br Prof. Thiago A. S. Pardo

Introdução à Linguagem

- o Linguagem de alto nível
 - o Ao ler o comando, já se presume o que ele significa!
- Vários tipos de programação:
 - Modular: divisão do algoritmo em blocos
 - Orientada a objetos: classes e objetos referenciados
 - Funcional: aplicação de funções matemáticas
- Tipagem **forte** e dinâmica
- o Grande coleção de bibliotecas
- Código aberto

Introdução à Linguagem

- o Instalação e uso: site oficial do Python
 - https://www.python.org/downloads/



- Os códigos podem ser executados:
 - Em programas como PyCharm, VS Code ou Sublime
 - por meio de linha de comando (prompt Windows, terminal Linux, IDLE Python...)
 - o python programa.py
 - o ./programa.py

TIPOS DE DADOS

```
>>> X
10
>>> y = "roney lira"
>>> A
'roney lira'
>>> k = 1.8 - 1.5
>>> k
0.300000000000000004
>>> type(x)
<class 'int'>
>>> type(y)
<class 'str'>
>>> type(k)
<class 'float'>
>>> x > 6
True
>>> x > 15
False
>>>
```

- o Tipos de dados básicos
 - int, string, float, bool...
- O tipo de uma variável muda conforme o valor que lhe é atribuído.
 - Princípio da dinâmica
- o type (var)

Introdução à Linguagem

- Não é preciso terminar comandos com ;
- Não é preciso declarar o tipo de dados das variáveis

```
>>> x = 4+6
>>> X
10
>>> y = "roney lira"
>>> V
'roney lira'
>>> k = 1.8 - 1.5
>>> k
0.300000000000000004
>>> type(x)
<class 'int'>
>>> type (y)
<class 'str'>
>>> type(k)
<class 'float'>
>>>
```

TIPAGEM FORTE

```
>>> v = "1"
>>> q = 1
>>> v + q
Traceback (most recent call last):
   File "<pyshell#16>", line 1, in <module>
        v + q
TypeError: can only concatenate str (not "int") to str
>>> |
```

- o Ou seja, Python é uma linguagem que tem a característica de que não permite um mesmo dado ser tratado como se fosse de outro tipo.
- Mais sobre isso <u>aqui</u>.

Indentação

- o Bom, Python não usa nenhum limitante para estrutura de bloco, comum em outras linguagens
 - {, }, ;, begin, end, e por aí vai.
- A estrutura do bloco é definida pela indentação, ou seja, o alinhamento dos comandos é que define a estrutura!

```
if num % 2 = 0:
    par = par + 1
    print("PAR")
else:
    impar = impar + 1
    print("IMPAR")
```

Para nossas práticas, usaremos...

- Listas e Tuplas
- Dicionários
- Arquivos
- Strings
 - Textos, cara do nosso PLN né! =)
- Claro, existem beeeem mais coisas relacionadas ao Python!
 - Estruturas de controle, funções, classes, programação funcional, uso de *frameworks* diversos...
- E também frameworks relacionados ao PLN, como NLTK e spaCy
 - o Em breve nas telinhas da disciplina!

LISTAS E TUPLAS

- Estruturas de dados nativas da linguagem
 - list e tuple
- o Informações dentro das listas e tuplas podem ser de tipos diferentes
- Acesso sequencial: fatias (slicing) ou diretamente
- Métodos prontos para adicionar, remover, ordenar, procurar, contar, entre vários outros
- Listas: mutáveis e delimitadas por colchetes
- o Tuplas: imutáveis e delimitadas por parênteses

Listas - Métodos

```
l = list(range(5))
print(1)
l.append(5)
print(1)
l.insert(0,6)
print(1)
l.reverse()
print(1)
l.sort()
print(1)
[0, 1, 2, 3, 4]
[0, 1, 2, 3, 4, 5]
[6, 0, 1, 2, 3, 4, 5]
[5, 4, 3, 2, 1, 0, 6]
[0, 1, 2, 3, 4, 5, 6]
```

- o extend(L): inclusão de uma lista 12 (append)
- o remove (x): remove a primeira ocorrência de x
- o index (x): índice da primeira ocorrência de x
- o count (x): número de ocorrências de x na lista

o Funciona como uma sublista da lista

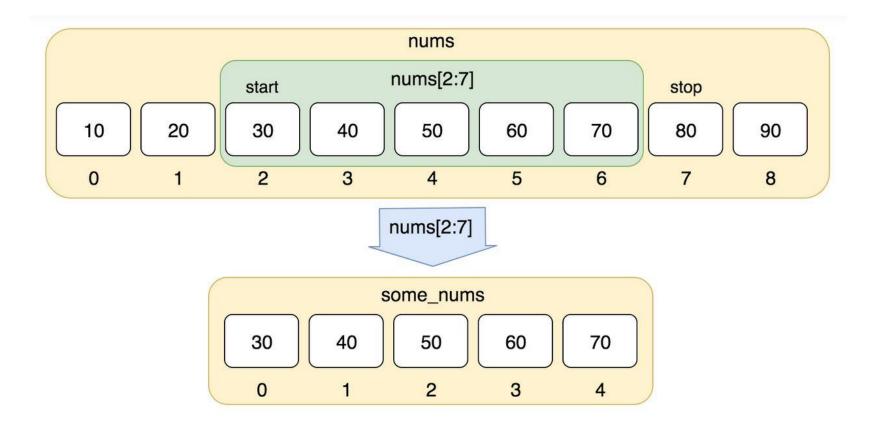
```
>>> 1 = list(range(10))
>>> 1
[0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
>>> 1[2:7]
[2, 3, 4, 5, 6]
```

- A notação [2:7] significa qual o intervalo da lista original você pretende retornar
 - Lembrando que os índices são contados a partir do zero. Assim, no nosso exemplo, queremos do 3º elemento até o 7°.

• Também é possível pular elementos, incluindo a quantidade em um outro índice.

```
>>> 1 = list(range(10))
>>> 1
[0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
>>> 1[2:7]
[2, 3, 4, 5, 6]
>>> 1[2:7:2]
[2, 4, 6]
```

• A notação [2:7:2] significa, então, que queremos uma sublista do 3º ao 7º elemento, pulando de 2 em 2 elementos.



 Conseguimos também retornar os n primeiros elementos e os n últimos elementos por meio do slicing.

- o Os n primeiros elementos: [:n]
 - Ou seja, deixa-se vazio o primeiro index da lista

- o Os n últimos elementos: [-n:]
 - Deixa-se vazio o segundo index da lista

• Além disso, várias outras combinações podem ser feitas...

- Retornar todos os elementos menos os n últimos:
 - 1[:-n]
- o Pular de **n** em **n** elementos na lista:
 - 1[::n]
- O reverse () pode ser representado por l[::-1]
- E vááárias outras possibilidades!
 - Dá uma olhada aqui, ó!

TUPLAS

- Tuplas seguem o mesmo conceito das listas, porém com uma diferença importante: são imutáveis.
- Existe uma outra diferença: tuplas são para elementos **heterogêneos**, ou seja, tipos diferentes dentro da tupla.
 - Porém, como o Python é uma linguagem dinâmica, essa característica também aparece nas listas.
 - Cabe ao programador decidir tal característica.

TUPLAS

o Por exemplo, se você tentar modificar um elemento da tupla, você não consegue. Exemplo:

```
>>> t = (1, 'roney', 2, 'lira')
>>> t
(1, 'roney', 2, 'lira')
>>> t[0] = 5
Traceback (most recent call last):
   File "<pyshell#5>", line 1, in <module>
        t[0] = 5
TypeError: 'tuple' object does not support item assignment
>>> |
```

TUPLAS

- Então você pode perguntar: Mas então, qual a diferença entre usar uma tupla em vez de uma lista e vice-versa?
- o Por serem imutáveis, tuplas representam informações que **não devem ser modificadas**,
 - Exemplos: vetores dos embeddings e classes morfossintáticas retornadas por um tagger.
- Arranjo das tuplas é similar ao das listas, só não se usam os métodos para modifica-las.
 - Apenas o count () e o index () estão disponíveis.

• São estruturas de dados bem úteis que permitem armazenar e recuperar informações por pares chave-valor.

- Arrays associativos
 - Analogia ao *hashing*
- o De forma mais "simples": é uma lista que podemos acessar seus elementos através de uma chave.

```
>>> dic = {}
>>> dic['roney'] = 6
>>> dic['thiago'] = 12
>>> dic['alguém'] = 4
>>> print(dic)
{'roney': 6, 'thiago': 12, 'alguém': 4}
>>> dic['roney']
6
>>> dic['roney'] = 'seis'
>>> dic['roney']
'seis'
>>> |
```

• Os valores podem ser representados por qualquer tipo de dados e quaisquer estrutura: uma string, int, bool, lista, tupla, outro dicionário...

Como percorrer os dicionários:

```
>>> print(dic.keys())
dict keys(['c', 'b', 'a', 1.5, 4])
>>> print(dic.values())
dict values([10, 20, 30, 40, 50])
>>> type(dic.keys())
<class 'dict keys'>
>>> dic.keys[0]
Traceback (most recent call last):
  File "<pyshell#48>", line 1, in <module>
    dic.keys[0]
TypeError: 'builtin function or method' object is not subscriptable
>>> list(dic.keys())
['c', 'b', 'a', 1.5, 4]
>>> list(dic.items())
[('c', 10), ('b', 20), ('a', 30), (1.5, 40), (4, 50)]
>>> list(dic.values())
[10, 20, 30, 40, 50]
>>> dic
{'c': 10, 'b': 20, 'a': 30, 1.5: 40, 4: 50}
>>> for k, v in dic.items():
        print(k, 'tem como valor', v)
c tem como valor 10
b tem como valor 20
a tem como valor 30
1.5 tem como valor 40
4 tem como valor 50
>>>
```

a tem como valor 30 1.5 tem como valor 40 4 tem como valor 50

>>>

Como percorrer os dicionários:

```
Verifico as chaves do dicionário
>>> print(dic.keys())
dict keys(['c', 'b', 'a', 1.5, 4])
>>> print(dic.values())
                                              Verifico os valores presentes no dicionário
dict values([10, 20, 30, 40, 50])
>>> type(dic.keys())
<class 'dict keys'>
>>> dic.keys[0]
                                               O tipo retornado é próprio do dicionário,
Traceback (most recent call last):
  File "<pyshell#48>", line 1, in <module>
                                               então não consigo manipular...
    dic.keys[0]
TypeError: 'builtin function or method' object is not subscriptable
>>> list(dic.keys())
                                         Dessa forma, transformo-o em uma lista
['c', 'b', 'a', 1.5, 4]
>>> list(dic.items())
[('c', 10), ('b', 20), ('a', 30), (1.5, 40), (4, 50)]
                                                         Aqui temos as informações
>>> list(dic.values())
                                                         completas, com chave-valor
[10, 20, 30, 40, 50]
>>> dic
{'c': 10, 'b': 20, 'a': 30, 1.5: 40, 4: 50}
>>> for k, v in dic.items():
        print(k, 'tem como valor', v)
                                             Finalmente,
                                                              usando
                                             estrutura de controle
                                                                      for.
c tem como valor 10
                                             podemos iterar pelo dicionário e
b tem como valor 20
```

retornar informações!

• Arquivos são um tipo nativo do Python que permite a sua manipulação sem precisar importar nenhum módulo.

o Primeiro é necessário criar um objeto que represente o arquivo e então abri-lo, para começar a manipular:

```
infile = open("qbdata.txt", 'r')
outfile = open("result.txt", 'w')
```

```
infile = open("qbdata.txt", 'r')
outfile = open("result.txt", 'w')
```

- o Importante: atenção nos parâmetros para abertura de arquivo.
 - $\mathbf{r} = read$, ou seja, apenas para **leitura** do arquivo;
 - $\mathbf{w} = write$, ou seja, apenas para **escrita** no arquivo;
 - **a** = *append*, ou seja, **escrita no final** do arquivo.
 - Existem outros parâmetros mais direcionados, mas que não serão explorados nessa aula.
- Ao final do uso do arquivo, sempre fechá-lo com o comando close().

• Assim que o arquivo é aberto, seu conteúdo é armazenado na variável criada para tal. A partir daí, a manipulação deve ser feita com essa variável.

```
4 conteudo = infile.read()
5 print(conteudo)
6

Colt McCoy QB, CLE 135 222 1576 6 9 60.8% 74.5

Josh Freeman QB, TB 291 474 3451 25 6 61.4% 95.9

Michael Vick QB, PHI 233 372 3018 21 6 62.6% 100.2

Matt Schaub QB, HOU 365 574 4370 24 12 63.6% 92.0

Philip Rivers QB, SD 357 541 4710 30 13 66.0% 101.8

Matt Hasselbeck QB, SEA 266 444 3001 12 17 59.9% 73.2

Jimmy Clausen QB, CAR 157 299 1558 3 9 52.5% 58.4

Joe Flacco QB, BAL 306 489 3622 25 10 62.6% 93.6

Kyle Orton QB, DEN 293 498 3653 20 9 58.8% 87.5
```

Todo o conteúdo do arquivo em uma única variável

 Assim que o arquivo é aberto, seu conteúdo é armazenado na variável criada para tal. A partir daí, a manipulação deve ser feita com essa variável.

```
4 lista_conteudo = infile.readlines()
5 print(lista_conteudo)
6
```

```
['Colt McCoy QB, CLE 135 222 1576 6 9 60.8% 74.5\n', 'Josh Freeman QB, TB 291 474 3451 25 6 61.4% 95.9\n', 'Michael Vick QB, PHI 233 372 3018 21 6 62.6% 100.2\n', 'Matt Schaub QB, HOU 365 574 4370 24 12 63.6% 92.0\n', 'Philip Rivers QB, SD 357 541 4710 30 13 66.0% 101.8\n', 'Matt Hasselbeck QB, SEA 266 444 3001 12 17 59.9% 73.2\n', 'Jimmy Clausen QB, CAR 157 299 1558 3 9 52.5% 58.4\n', 'Joe Flacco QB, BAL 306 489 3622 25 10 62.6% 93.6\n', 'Kyle Orton QB, DEN 293 498 3653 20 9 58.8% 87.5\n', 'Jason Campbell QB, OAK 194 329 2387 13 8 59.0% 84.5\n', 'Peyton Manning QB, IND 450 679 4700 33 17 66.3% 91.9\n', 'Drew Brees QB, NO 448 658 4620 33 22 68.1% 90.9\n', 'Matt Ryan QB, ATL 357 571 3705 28 9 62.5% 91.0\n', 'Matt Cassel QB, KC 262 450 3116 27 7 58.2% 93.0\n', 'Mark Sanchez QB, NYJ 278 507 3291 17 13 54.8% 75.3\n', 'Brett Favre QB, MIN 217 358 2509 11 19
```

• Cada linha do arquivo em uma lista

• Escrita:

A função **range ()** retorna uma série numérica no intervalo enviado como argumento.

```
2 outfile = open("result.txt", 'w')
3
4 outfile.write("Números de 1 a 10\n")
5 for i in range(1,11):
    outfile.write(str(i)+'\n')
7
```

[Finished in 0.4s]

```
result - Notepad

File Edit Format View Help

Números de 1 a 10

1

2

3

4

5

6

7

8

9

10
```

• Escrita:

```
2 outfile = open("result.txt", 'w')
3
4 outfile.write("Adicionando números de 11 a 20\n")
5 for i in range(11,21):
6    outfile.write(str(i)+'\n')
7
```

[Finished in 0.4s]

```
result - Notepad

File Edit Format View Help

Adicionando números de 11 a 20

11

12

13

14

15

16

17

18

19

20
```

• Escrita com append (a):

```
2 outfile = open("result.txt", 'a')
3
4 outfile.write("Adicionando números de 11 a 20\n")
5 for i in range(11,21):
    outfile.write(str(i)+'\n')
7
```

```
result - Notepad
File Edit Format View Help
Números de 1 a 10
Adicionando números de 11 a 20
11
12
13
14
15
16
17
18
19
20
```

- Na escrita, a função write() aceita apenas strings, ou seja, se você colocar como parâmetro um inteiro ou qualquer outro tipo, um erro é lançado.
- Basta fazer o *cast* da variável ou da informação que pretende escrever no arquivo por meio de **str(dado)**.

```
2 outfile = open("result.txt", 'a')
3
4 outfile.write("Adicionando números de 11 a 20\n")
5 for i in range(11,21):
6   outfile.write(str(i)+'\n')
7
```

- Tipo de dados mais importante no trabalho em PLN, afinal, é o tipo que representa os textos!
- o O Python define o tipo de dados como str
- As strings podem ser delimitadas por aspas simples, aspas duplas ou aspas triplas.

```
>>> 'aspas simples'
'aspas simples'
>>> "aspas duplas"
'aspas duplas'
>>> """aspas triplas"""
'aspas triplas'
>>> """aspas triplas tem uma propriedade que ignoram
a quebra de linha, então a string aparece
como ela é escrita"""
'aspas triplas tem uma propriedade que ignoram\na quebra de linha, então a string aparece\ncomo ela é escrita'
>>> |
```

o Interessante é que as strings são imutáveis, ou seja, da forma que elas são criadas, não é possível alterá-las diretamente. Exemplo:

```
>>> r = 'roney'
>>> r[0] = 'l'
Traceback (most recent call last):
   File "<pyshell#68>", line 1, in <module>
        r[0] = 'l'
TypeError: 'str' object does not support item assignment
```

• Entretanto, é possível manipulá-las de diversas formas. Se é necessário essa alteração, pode ser feito assim:

```
>>> nr = 'l' + r[1:]
>>> nr
'loney'
```

 Porém, é possível adicionar novas informações àquela string já criada por meio do operador +

```
>>> r = r + 'lira'
>>> r
'roneylira'
>>> |
```

• O operador + também serve para concatenar strings com outros tipos em string.

```
>>> pi = 3.14
>>> info = 'o valor de pi é = ' + pi
Traceback (most recent call last):
   File "<pyshell#74>", line 1, in <module>
        info = 'o valor de pi é = ' + pi
TypeError: can only concatenate str (not "float") to str
>>> info = 'o valor de pi é = ' + str(pi)
>>> info
'o valor de pi é = 3.14'
>>>
```

• E, claro, é possível usar o slicing na string.

```
>>> string = 'roney'
>>> string[0]
'r'
>>> string[1:]
'oney'
>>> string[2:4]
'ne'
>>> string[:]
'roney'
>>> string[1:10]
'oney'
>>> |
```

• String possuem uma variedade ENORME de funções. Aqui as que serão trabalhadas nessa aula:

```
• len()
```

- strip()
- lower(), upper()
- replace()
- split()

• Uma lista com mais funções sobre strings pode ser encontrada <u>aqui</u>.

olen() – retorna o tamanho da string em referência a caracteres e espaços.

```
>>> s = 'instituto de ciências matemáticas e de computação'
>>> len(s)
49
>>> r = 'roney l'
>>> len(r)
7
```

o lower() e upper() — retorna a string inteiramente em minúsculo ou em maiúsculo.

```
>>> k = 'Roney Lira'
>>> k.lower()
'roney lira'
>>> k.upper()
'RONEY LIRA'
>>> |
```

o strip() – exclui os espaços existentes no início ou no final da string.

```
>>> r = ' Aula sobre strings '
>>> r.strip()
'Aula sobre strings'
>>> |
```

• replace() – substitui uma string com outra string. Modo mais fácil de fazer a alteração na string que foi comentado um pouco antes.

```
>>> r = 'roney'
>>> r.replace('r', 'l')
'loney'
>>> r = 'roney lira'
>>> r.replace('r', 'l')
'loney lila'
>>> |
```

- o split() retorna um conjunto de substrings em forma de lista.
 - Podem ser usados parâmetros para fazer essa separação: uma palavra, um caractere, um escape, entre outros. Caso não seja utilizado **nenhum** argumento, a função trata como **separação por espaços**.

```
>>> s = 'instituto de ciências matemáticas e de computação'
>>> s.split()
['instituto', 'de', 'ciências', 'matemáticas', 'e', 'de', 'computação']
>>> s.split('matemáticas')
['instituto de ciências ', ' e de computação']
>>> s.split('de')
['instituto ', ' ciências matemáticas e ', ' computação']
>>> |
```

• Veja nesse exemplo que o split pode ser "gerador" de utilização de várias outras funções, como o strip().

- split() retorna um conjunto de substrings em forma de lista.
 - Interessante que agora podemos contar a quantidade de palavras que existem numa string.

```
>>> s = 'instituto de ciências matemáticas e de computação'
>>> len(s.split())
7
```

o A operação inversa do split() é o join().

```
>>> sl = s.split()
>>> sl
['instituto', 'de', 'ciências', 'matemáticas', 'e', 'de', 'computação']
>>> sj = " ".join(sl)
>>> sj
'instituto de ciências matemáticas e de computação'
>>> sj = "/".join(sl)
>>> sj
'instituto/de/ciências/matemáticas/e/de/computação'
>>> sj = "-".join(sl)
>>> sj
'instituto-de-ciências-matemáticas-e-de-computação'
>>> sj
```

• Caracteres de escape:

- \n = quebra de linha
- \t = tabulação
- \\ = barra invertida
- Entre outros...

```
1  s = 'instituto\nde ciências matemáticas\n e de computação'
2  print(s)
3  s = 'instituto de \'ciências matemáticas\' e de computação'
4  print(s)
5  s = 'instituto \t de ciências matemáticas e \t de computação'
6  print(s)
7  s = 'instituto \\ de ciências matemáticas e \\ de computação'
8  print(s)
```

instituto de ciências matemáticas e de computação instituto de 'ciências matemáticas' e de computação instituto de ciências matemáticas e de computação instituto \ de ciências matemáticas e \ de computação

- 1. Dado o arquivo qbdata.txt, retorne o *rating* de cada QB na forma "nome do QB teve valor XX.X' e escreva em um arquivo novo.
 - Arquivo qbdata.txt disponível <u>aqui</u>.

• 1. Dado o arquivo qbdata.txt, retorne o rating de cada QB na forma "nome do QB teve valor XX.X"

```
1 Colt McCoy QB, CLE 135 222 1576 6 9 60.8% 74.5

2 Josh Freeman QB, TB 291 474 3451 25 6 61.4% 95.9

3 Michael Vick QB, PHI 233 372 3018 21 6 62.6% 100.2

4 Matt Schaub QB, HOU 365 574 4370 24 12 63.6% 92.0

5 Philip Rivers QB, SD 357 541 4710 30 13 66.0% 101.8

6 Matt Hasselbeck QB, SEA 266 444 3001 12 17 59.9% 73.2

7 Jimmy Clausen QB, CAR 157 299 1558 3 9 52.5% 58.4
```

- Percebe-se que as informações que são requeridas são a primeira e a última de cada linha;
- É visto também que a separação entre as informações é feita por meio de espaços ou tabulação;
- Algoritmo: para cada linha, fazer a separação dela e por meio do *slicing* de listas, pegar a primeira e a última informação e montar a string final.

2. Pensando em uma agenda, construa um dicionário com informações do contato sendo:
 CPF, nome, telefone e user no Twitter. Ao final, imprima todos os contatos na forma

CPF: nome, telefone (user)

2. Pensando em uma agenda, construa um dicionário com informações do contato sendo:
 CPF, nome, telefone e user no Twitter. Ao final, imprima todos os contatos na forma

CPF: nome, telefone (user)

- De cara já dá para perceber que a chave vai ser o CPF, então na criação do dicionário, deve-se incluir na forma dic[CPF] = ?
- o Temos mais de uma informação. O que seria interessante usar? Uma lista, uma tupla, outro dicionário?
- Ao final, para imprimir todos os contatos, há claramente a manipulação de strings.